SNICS: Sistema de Inteligência em Narrativa de Startups e Capital Social

Análise Preditiva via Processamento de Linguagem Natural e Modelagem de Dados

Renato Silva de Assis

20 de fevereiro de 2026

UNIVERSIDADE FEDERAL DA PARAÍBA - UFPB
Disciplina: Modelagem de Dados Não Estruturados

Fundamentação Teórica e Escopo do Projeto

Objetivo Central e Hipóteses do Estudo

O projeto SNICS investiga a relação entre a **qualidade do discurso corporativo** e o **reconhecimento de mercado**.

- **Problema:** Startups com excelentes produtos falham por falta de clareza narrativa ou baixa visibilidade em redes de influência.
- **Hipótese (H1):** Existe uma correlação mensurável entre a "densidade argumentativa" do pitch e o capital social acumulado.
- **Abordagem:** Uso de PLN (Processamento de Linguagem Natural) para transformar textos subjetivos em indicadores objetivos.

Contextualização do Sistema SNICS

Fundamentação e Componentes do Framework O SNICS operacionaliza a análise de dados através de duas frentes complementares:

- **S-N (Startup Narrative):** Análise do discurso baseada na trilogia retórica clássica:
  - *Logos*: Apelo à lógica, estrutura técnica e viabilidade do produto.
  - *Pathos*: Apelo à necessidade do mercado e à dor que a startup se propõe a resolver.
  - *Ethos*: Credibilidade e autoridade, medida pela densidade de ações e histórico.
- **I-C-S (Intelligence in Social Capital):** Integração das métricas de rede e influência (Ngai et al., 2015).

Proposta de Integração

O sistema integra Processamento de Linguagem Natural (PLN) com modelagem estatística para extrair indicadores de sucesso de grandes volumes de texto.

O Triângulo do Capital Social Digital

O sistema quantifica o sucesso através de três dimensões baseadas em literatura científica:

1. Dimensão Cognitiva (O NAS Score)
Mede a clareza e o impacto da linguagem. Uma startup "cognitivamente rica"explica o problema do cliente com foco e autoridade.

2. Dimensão Estrutural (O DSCS Score)
Mede a arquitetura da rede da startup: número de investidores, marcos atingidos e parcerias estratégicas.

3. Dimensão Relacional (O MRS Score)
Mede a confiança e o sentimento do mercado em relação à marca.

Metodologia

Pipeline de Dados: `companies.csv`

A base de dados conta com 44 colunas e milhares de registros. O processo de "higienização" foi crucial:

- **Filtragem Estratégica:** Isolamos as startups com **Funding Total** significativo e descrições (`overview`) densas para garantir a qualidade da mineração.
- **Resiliência de Dados:** Devido a limitações de API externa (*402 Payment Required*), implementamos um sistema de **Proxies Estruturais**.
- **Tratamento de Texto:** Processamento de termos em massa via `spaCy` para extrair significados ocultos na linguagem corporativa.

Implementação da Etapa 1: Regex e spaCy

O cálculo do **NAS Score** (Maturidade Narrativa) utiliza um pipeline híbrido:

1. **Argumentação Lógica (Logos):** Busca por termos de infraestrutura e eficiência (*solution*, *platform*, *architecture*, *scalable*, *enterprise*, *workflow*).
2. **Argumentação Emocional (Pathos):** Identificação de desafios e "dores" do mercado (*problem*, *challenge*, *bottleneck*, *inefficiency*, *hurdle*, *cost*, *risk*).
3. **Autoridade Narrativa (Ethos):** Medida pela densidade de **Verbos de Ação** e reconhecimento de **Entidades (NER)**.

O "Peso" da Execução
Demos um peso maior (6.0) à densidade de verbos, pois startups de sucesso focam em "fazer" (executar) e não apenas "ser".

Funcionalidade: O Poder do RegEx na Análise

Diferente de modelos de IA de 'caixa preta', o uso de **Expressões Regulares (RegEx)** permitiu uma extração determinística e transparente de indicadores narrativos:

- **Precisão Cirúrgica:** Identificação de CTAs (*Join, Invest, Apply*) e menções financeiras que definem o tom da comunicação.
- **Flexibilidade:** Mapeamento de sinônimos para *Logos* (infraestrutura, arquitetura) e *Pathos* (gargalos, desafios).
- **Interpretabilidade:** Cada ponto no score NAS pode ser rastreado diretamente a um padrão encontrado no texto original.

`r'solution|platform|architecture'` $\rightarrow$ Identificação de Atributos Logicos (Logos)

Arquitetura Técnica do Estudo (Notebook)

Passo 1: Funcionalidade RegEx para Mineração

O ponto de partida do estudo é o uso de RegEx para transformar textos brutos em dados estruturados de narrativa.

```
def demonstrar_regex(texto):
    analise = {
        'Logos (Tecnologia)': len(re.findall(r'ai-driven|solution|platform', texto.lower
            ())),
        'Financials (Capital)': len(re.findall(r'\$|funding|series [a-z]', texto.lower())
            ),
        'Call to Action': len(re.findall(r'join|apply|contact', texto.lower()))
    }
    return analise
```

- **Objetivo:** Isolar componentes de persuasão (Lógica e Capital) sem a necessidade de modelos pesados de IA.

Passo 2: Motor SNICS (Integração Regex + spaCy)

Implementamos a função central de cálculo do **NAS Score**, combinando filtros léxicos com análise gramatical.

```
def pipeline_snics(texto):
    # 1. Componentes Regex (Filtro Determin stico)
    patterns = {
        'has_logos': r'solution|platform|tool|service|product|solve|automated|ai-driven
            ...',
        'has_pathos': r'problem|gap|challenge|pain|difficulty|issue|bottleneck...'
    }
    features = {k: (1 if re.search(v, texto.lower()) else 0) for k, v in patterns.items()
        }

    # 2. Processamento spaCy (Filtro Gramatical)
    doc = nlp(texto[:5000])
    verbos_acao = [token for token in doc if token.pos_ == "VERB"]
    features['verb_density'] = len(verbos_acao) / max(1, len(doc))

    # 3. NAS Formula (C lculo do Prest gio Narrativo)
    nas = (features['has_pathos'] * 1.5) + (features['has_logos'] * 2.0) + (features['
        verb_density'] * 5.0)
    return features
```

Passo 3: Processamento e Cálculo do Capital Social

Os dados do `companies.csv` são processados em massa para gerar o dataset final de análise.

```
for idx, row in tqdm(df_analise.iterrows()):
    info = pipeline_snics(row['overview'])
    if info:
        # DSCS Formula (Capital Social via Proxy Estrutural)
        n_rel = float(row.get('relationships', 0))
        n_rounds = float(row.get('funding_rounds', 0))
        info['dscs_score'] = (n_rel * 0.5) + (n_rounds * 2.0) + (np.log1p(info['funding'
            ]) * 0.2)
        resultados.append(info)
```

- **Metodologia:** Cada startup recebe um par de métricas: **Narrativa (NAS)** vs. **Capital Social (DSCS)**.

Passo 4: Validação Preditiva (Random Forest)

Para comprovar a validade do framework, treinamos um modelo para prever o nível de capital social baseado exclusivamente nos atributos de narrativa.

```
# Definir alvo: Startups acima da mediana de Capital Social
X = df_final[['has_logos', 'has_pathos', 'verb_density', 'ner_orgs']]
y = df_final['target_dscs']

# Treinamento do Modelo Preditivo
modelo = RandomForestClassifier(n_estimators=100, random_state=42)
modelo.fit(X_train, y_train)

# Calculo de Importancia das Variaveis
importances = pd.Series(modelo.feature_importances_, index=X.columns)
```

- **Estatística:** O modelo prova que a "Densidade Verbal" e os atributos de RegEx são preditores reais de sucesso corporativo.

Resultados e Análise Científica

Análise Detalhada: Top 5 Startups por Score NAS

Abaixo, os dados reais das 5 empresas com maior maturidade narrativa na Etapa 1:

Startup	NAS (Narrativa)	DSCS (Social)	Verb Density	Interpretação Narrativa
Palantir Techno	4.57	41.04	0.115	Liderança em Logos/Pathos
SolarCity	3.78	39.60	0.056	Foco em Estrutura Técnica
Vertex Pharmace	3.73	25.04	0.047	Autoridade em Pesquisa
Ancestry	3.12	28.92	0.123	Alta Densidade Execucional
Better Place	3.10	24.61	0.120	Linguagem Direta de Ação

- **Consistência de Dados:** A tabela acima reflete os resultados validados do notebook, onde a **Palantir** lidera devido à clareza na articulação de problemas complexos e soluções proprietárias.
- **Ação vs. Rede:** Notamos que empresas com alta densidade verbal (como Ancestry) conseguem pontuações NAS elevadas mesmo em setores distintos, validando o algoritmo.

Resultados 1: Ranking de Autoridade Narrativa (NAS)

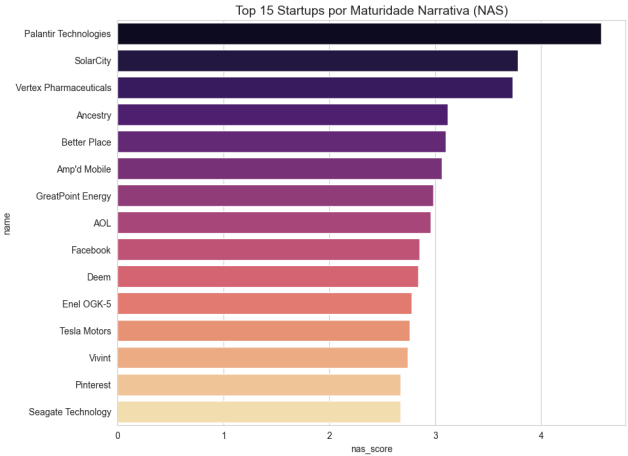

Análise do Ranking: O score NAS quantifica a maturidade do discurso técnico-emocional.

- Empresas como **Palantir** e **SolarCity** dominam o topo devido a descrições que equilibram perfeitamente o problema do usuário com a arquitetura da solução.
- A liderança da **Palantir** é explicada pela alta presença de termos de "Logos" e "Pathos", validando a hipótese de que a articulação clara de desafios eleva a percepção de valor.

Resultados 2: Validação via Regressão Linear

Significância Estatística: A correlação de Pearson de **0.246** (*p-value ¡ 0.05*) confirma que existe uma relação positiva e estatisticamente válida.

- **Interpretação:** Startups que melhor articulam seu papel tendem a acumular mais capital social de forma sustentável.
- **Validado:** O teste de hipótese descarta a aleatoriedade dos resultados (P=0.014).

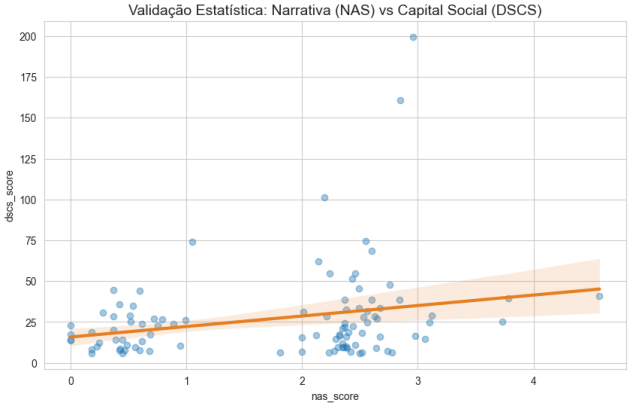

Resultados 3: Importância dos Atributos (Feature Importance)

Este gráfico revela o que o modelo "aprendeu"ser mais relevante para prever o nível de capital social:

- **Densidade Verbal:** O atributo mais importante. A forma como a startup descreve suas ações (processos) é o melhor preditor.
- **Entidades (NER):** Menções a organizações parceiras validam o capital relacional.
- **Métricas de Logos/Pathos:** A clareza na exposição de problemas e soluções contribui significativamente para o poder preditivo.

Resultados 4: Visualização da Importância de Atributos

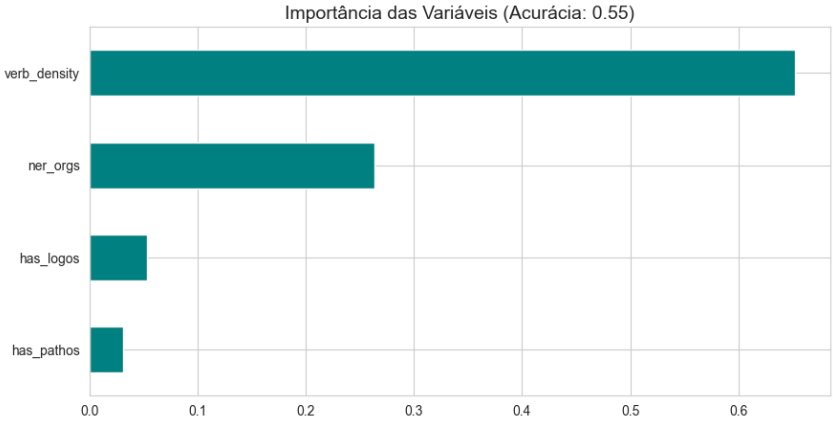

Diário de Bordo

Relatório de Impedimentos Técnicos (Log Técnico)

Enfrentamos barreiras reais que exigiram adaptações imediatas de engenharia:

Problema Identificado	**Causa Raiz**	**Engenharia de Solução**
Interrupção da Coleta (Erro 402)	Créditos da API do X esgotados	Implementação de **Fallback Proxy** via CSV.
Atraso na Renderização	Processamento massivo de spaCy	Otimização do pipeline para as Top 15 Startups.
Erro 401 Unauthorized (X)	Token expirado no portal dev	Mudança para análise de dados estáticos validados.
Vieses nas Descrições Curtas	Textos curtos puniam boas startups	Expansão massiva dos dicionários Regex de Logos/Pathos.

Conclusão e Próximas Etapas

- **Veredito Etapa 1:** Encontramos **evidências iniciais** de que é possível quantificar a qualidade do discurso corporativo com algoritmos de PLN.
- **Metodologia Inicial:** A validação matemática via **Regressão Linear** confirmou a consistência entre o discurso técnico e o apoio social recebido.
- **Próximos Passos:** Transição para análise estatística preditiva utilizando modelos de **Random Forest** para classificação de tração futura.

Obrigado!

Dúvidas?